TRACK DE IA · CLASE 9 · IL3.1

Observabilidad en agentes LLM

Cómo ver qué hace un agente por dentro: logs, métricas, trazas y plataformas

«Un agente sin trazas es una caja negra que a veces acierta.»

Duoc UC · Viña del Mar

¿QUÉ ES CADA UNA?

Observabilidad, métricas y trazas

1

Observabilidad (logs)

Entender qué hizo tu agente con lo que dejó registrado. Su base: los logs.

Responde: ¿qué pasó?

```
INFO:root:Recibido mensaje:
Hola
```

2

Métricas

Números que resumen al agente: tiempo, tokens, costo y errores.

Responde: ¿cuánto?

```
latencia: 5.22 s
error: 2 de 11 pasos
```

3

Trazas

Cada paso de una ejecución, en orden: qué entró, qué salió y qué decidió.

Responde: ¿por dónde pasó y por qué?

```
decidir → tool → responder
```

CONCEPTO

Observar no es depurar

Depurar

CUÁNDO

Cuando ya sabes qué falló

DÓNDE

En tu máquina, reproduciendo el caso

CON QUÉ

print, breakpoints, leer el código

Observar

CUÁNDO

Siempre, antes de saber qué fallará

DÓNDE

En las ejecuciones reales

CON QUÉ

Logs, métricas y trazas guardadas

> Con un LLM no siempre puedes reproducir el fallo: la misma pregunta puede tomar otro camino. Por eso se registra mientras ocurre.

EL PROBLEMA

¿Por qué cuesta observar un agente?

1 **Decide su propio camino**

Tú le das las opciones; el modelo elige cuál usar y cuándo.

2 **Falla sin avisar**

Su error típico es una respuesta convincente pero incorrecta.

3 **Su costo varía**

Cada llamada gasta tokens distintos, y hace varias por pregunta.

4 **No siempre se repite**

La misma pregunta puede tomar otro camino la próxima vez.

NOTEBOOK 1 · MINIAGENT

Cinco agentes, de menos a más pasos

1

Llamada simple

Pregunta → modelo → respuesta.

Steps: responder

Mira: prompt, respuesta y tokens

2

Cadena de pasos

Pasos fijos, uno tras otro.

Steps: analizar → responder

Mira: ¿el paso 2 recibe lo del paso 1?

3

Con herramientas

El modelo decide si usar una tool.

Steps: decidir → (tool) → responder

Mira: qué tool eligió y con qué input

4

Con memoria

Arrastra las preguntas anteriores.

Steps: responder con historial

Mira: qué historial entró al prompt

5

Agente multi-paso

Analiza, decide y actúa.

Steps: analizar → decidir → (tool) → responder

Mira: el camino completo

SEÑALES CLAVE

Qué registrar en cada paso

Lo que entró

- Prompt completo
- Modelo
- Historial o contexto

Lo que salió

- Respuesta
- Herramienta y su input
- Decisión tomada

Lo que costó

- Tokens de entrada
- Tokens de salida
- Latencia
- Costo

Cómo terminó

- Estado: ok o error
- Mensaje de error
- Fecha y hora
- IDs de sesión y paso

> Regla práctica: lo que no registraste hoy, no lo puedes investigar mañana.

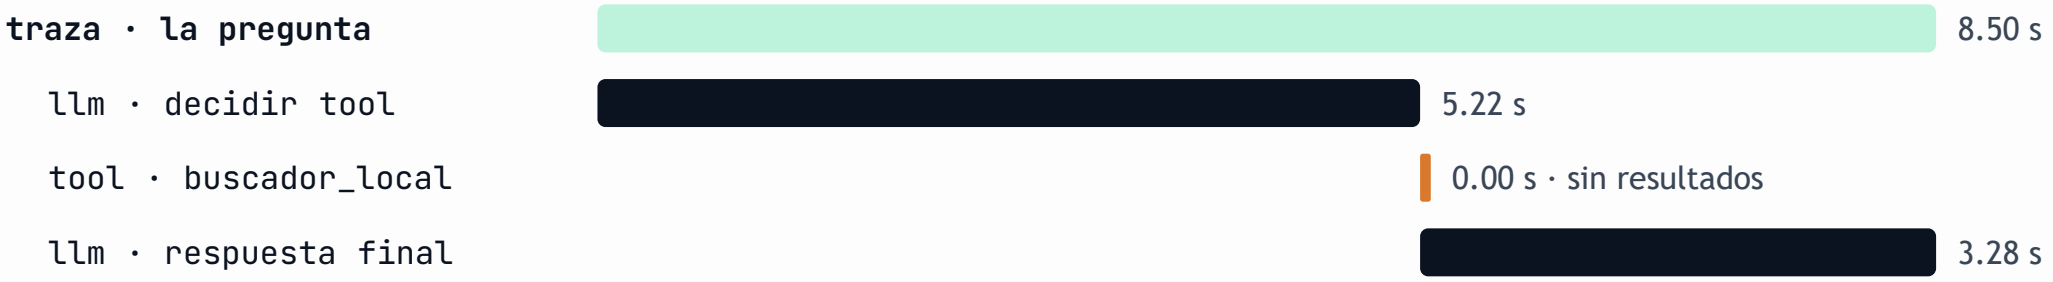
NOTEBOOK 2

Traza y span

Traza Una ejecución completa: de la pregunta a la respuesta.

Span Cada paso dentro de la traza, con inicio, fin y estado.

Traza real · «Busca información sobre observabilidad.» · 8.50 s sumando los spans



61 % del tiempo se fue en decidir la herramienta… y la herramienta no encontró nada.

MÉTRICAS

Cuatro números para operar un agente

Latencia

`segundos por paso`

Dice qué paso es lento. Notebook 2: hasta 5.22 s solo en decidir la tool.

Tokens

`entrada + salida`

Cuánto texto mueve cada llamada. Cada paso extra del agente suma.

Costo

`tokens ÷ 1 M × precio por millón`

El precio cambia según proveedor y modelo: se revisa en su página.

Tasa de error

`pasos con error ÷ total`

Notebook 2: 2 de 11 pasos. Los errores silenciosos no cuentan aquí.

> **Medido vs. estimado:** en los notebooks los tokens son fijos (30 y 50) o estimados (palabras × 1,2). En producción se leen de la respuesta de la API.

LO QUE MUESTRAN LAS TRAZAS

Tres fallas que solo se ven en la traza

FALLA 1

Herramienta equivocada

Notebook 2 · «Consulta el archivo CSV sobre clima.»

```
tool: calculadora
input: "."
estado: error
```

Pidió el CSV y terminó en la calculadora.

FALLA 2

Paso que no aporta

Notebook 1 · cadena de pasos

```
paso 1: análisis listo
paso 2: prompt sin análisis
```

Se pagó un paso que nadie usó.

FALLA 3

Error silencioso

Notebook 2 · «Calcula 45 + 81.»

```
paso 1: decidir → error
paso 2: responder → ok
salida: 126
```

Falló la decisión, pero nadie se enteró.

NOTEBOOK 3

De la tabla casera a una plataforma

Aspecto	Registro casero	Plataforma
Forma	Tabla plana, llena de celdas vacías (NaN)	Árbol de spans con padres, hijos y tiempos
Sesiones	Las armas tú con un session_id	Agrupadas y navegables
Versiones	Comparas a mano	Lado a lado, por prompt o modelo
Evaluaciones	No hay	Automáticas sobre ejecuciones reales
Alertas	No hay	Por error, latencia o costo

PLATAFORMAS

Tres opciones conocidas

Langfuse

Open source · self-hosteable

- Trazas, evaluaciones y gestión de prompts
- En tu propio servidor o en su nube
- SDK sobre OpenTelemetry

Phoenix

De Arize AI · open source

- Se instala con pip y corre en tu máquina
- Trazas y evaluaciones
- Cómodo para notebooks y desarrollo

LangSmith

De LangChain

- Integración directa con LangChain
- Trazas, datasets y evaluaciones
- Ya la usamos: el notebook 3 baja el prompt del agente desde ahí

> **Lo común:** todas reciben spans. OpenTelemetry es el estándar abierto que permite mandarlos sin casarse con una sola plataforma.

CIERRE

Tres ideas para llevarse

1. **«estado: ok» no significa respuesta correcta.**
   Un LLM falla con una respuesta convincente, no con una excepción.

2. **Registra cada paso, no solo el final.**
   Entrada, salida, tiempo, tokens, estado y la decisión tomada.

3. **La traza muestra el camino; la plataforma te ahorra armarla.**
   Langfuse, Phoenix o LangSmith reciben los spans y los ordenan por ti.

Ahora, a los notebooks: 1 · fundamentos → 2 · trazabilidad → 3 · plataformas